

UNIVERSIDAD TORCUATO DI TELLA

Maestría en Econometría

TRABAJO PRÁCTICO INTEGRADOR

Movilidad laboral entre formalidad e informalidad en Argentina

Evidencia longitudinal a partir de la
Encuesta Permanente de Hogares, 2023–2026

Agustina Giménez

Maestría en Econometría

Índice

1. Introducción	2
2. Datos y metodología	3
2.1. Fuente de información	3
2.2. Construcción de la muestra	3
2.3. Identificación longitudinal	3
2.4. Definición de las variables	4
2.5. Estrategia econométrica	4
3. Análisis exploratorio de los datos	5
3.1. Estructura y cobertura de la base	5
3.2. Valores faltantes y disponibilidad de información	7
3.3. Características generales de las personas ocupadas	8
3.4. Características laborales	11
3.5. Relaciones bivariadas con la formalidad laboral	13
4. Movilidad entre formalidad e informalidad	17
4.1. Identificación longitudinal y construcción de las transiciones	17
4.2. Definición de los tipos de movilidad	17
4.3. Matriz de transición	18
4.4. Evolución temporal de las transiciones	19
4.5. Caracterización de las personas que experimentan movilidad	20
4.5.1. Categoría ocupacional	21
4.5.2. Sexo	21
4.5.3. Nivel educativo	22
4.5.4. Edad	23
4.5.5. Ingreso laboral	24
4.6. Síntesis de los patrones de movilidad	25
5. Modelización de la movilidad entre formalidad e informalidad	26
5.1. Especificación de los modelos	26
5.2. Distribución de las variables dependientes	26
5.3. Resultados de los modelos Logit	27
5.3.1. Transición Formal $\rightarrow$ Informal	27
5.3.2. Transición Informal $\rightarrow$ Formal	28
5.4. Síntesis de los principales resultados de los modelos	29
5.5. Distribución de las probabilidades predichas	30
5.6. Evaluación de la capacidad discriminatória	31
5.7. Evaluación de la clasificación y selección del umbral	33
5.8. Comparación entre el umbral convencional y el umbral óptimo	34
5.9. Matrices de confusión	35
5.10. Síntesis e interpretación de los resultados	35
6. Limitaciones	35
7. Conclusiones	37

1. Introducción

La movilidad laboral constituye una dimensión relevante para comprender la dinámica del mercado de trabajo, ya que permite analizar no solo la situación laboral de las personas en un momento determinado, sino también los cambios que experimentan a lo largo del tiempo. En particular, las transiciones entre empleos formales e informales permiten estudiar los movimientos de entrada y salida de la formalidad y caracterizar las condiciones asociadas a dichos cambios.

En este trabajo se analiza la movilidad entre formalidad e informalidad en el mercado de trabajo argentino a partir de los microdatos de la **Encuesta Permanente de Hogares (EPH)**. El análisis utiliza información longitudinal, lo que permite vincular las observaciones de una misma persona en períodos consecutivos y estudiar los cambios en su condición de formalidad. A partir de esta estructura se distinguen dos movimientos de interés: la transición de un empleo formal hacia uno informal y la transición de un empleo informal hacia uno formal.

La pregunta de investigación que guía el trabajo es:

¿Qué factores individuales y laborales están asociados con la movilidad entre formalidad e informalidad en el mercado de trabajo argentino?

El objetivo es caracterizar estas transiciones y analizar su relación con un conjunto de características individuales y laborales. En particular, se consideran variables como el sexo, la edad, el nivel educativo, la categoría ocupacional, las horas trabajadas, el ingreso laboral y la región de residencia. El análisis busca identificar patrones diferenciados entre las personas que pierden formalidad y aquellas que ingresan a un empleo formal.

Para abordar la pregunta de investigación, el trabajo se desarrolla en distintas etapas. En primer lugar, se realiza un análisis exploratorio de los microdatos, examinando su estructura, cobertura, valores faltantes y distribución de las principales variables. Este análisis permite, además, fundamentar las decisiones adoptadas para la construcción de la muestra y el tratamiento de los datos. En segundo lugar, se construye una base longitudinal que permite identificar las transiciones entre períodos consecutivos y se describe la movilidad observada entre formalidad e informalidad.

Posteriormente, se analizan las características individuales y laborales de las personas que experimentan cada tipo de transición. Finalmente, se estiman dos modelos de regresión logística: uno para la transición **Formal** → **Informal** y otro para la transición **Informal** → **Formal**. En ambos casos, las variables explicativas corresponden a características observadas en el período inicial de la transición. Además de analizar los coeficientes mediante odds ratios, se evalúa el desempeño predictivo de los modelos utilizando matrices de confusión, distintas métricas de clasificación y curvas ROC.

Los resultados deben interpretarse como **asociaciones** entre las características observadas y la probabilidad de experimentar cada transición, y no como efectos causales. En este sentido, el análisis permite caracterizar la movilidad de formalidad en el mercado laboral argentino y estudiar qué perfiles presentan distintas pautas de transición dentro del período analizado.

2. Datos y metodología

2.1. Fuente de información

La fuente de información seleccionada para este estudio es la Encuesta Permanente de Hogares (EPH), elaborada por el Instituto Nacional de Estadística y Censos (INDEC). La elección de esta base responde a las características de la pregunta de investigación, que busca analizar los movimientos de los trabajadores entre empleos formales e informales en el mercado de trabajo argentino.

La EPH resulta adecuada para este propósito porque combina información sobre la situación laboral de los individuos con características sociodemográficas y laborales que permiten caracterizar su inserción en el mercado de trabajo. En particular, la encuesta contiene información sobre condición de actividad, formalidad laboral, sexo, edad, educación, categoría ocupacional, intensidad laboral e ingresos. Esto permite estudiar las transiciones laborales conjuntamente con las características observables de las personas y de los empleos.

Una característica especialmente relevante para este trabajo es la estructura de identificación de los individuos de la EPH. La combinación de identificadores de vivienda, hogar y componente permite vincular las observaciones de una misma persona en distintos períodos. Esta posibilidad es fundamental para el objetivo del estudio, ya que la pregunta de investigación requiere observar cambios en la situación de formalidad y no únicamente diferencias entre individuos en un momento determinado.

Se utilizan los microdatos correspondientes al período comprendido entre el primer trimestre de 2023 y el primer trimestre de 2026. Esta ventana temporal permite disponer de múltiples observaciones trimestrales y construir una estructura longitudinal a partir de períodos consecutivos.

2.2. Construcción de la muestra

La unidad de análisis del estudio es el individuo ocupado observado en dos períodos consecutivos. A diferencia de un análisis transversal, en el que la situación laboral se estudia en un único momento, la estrategia adoptada permite observar si una misma persona mantiene o modifica su condición de formalidad entre dos períodos.

La muestra de análisis longitudinal se construye a partir del emparejamiento de individuos entre trimestres consecutivos. Para cada persona identificada en un período t , se busca su correspondiente observación en el período $t + 1$. De esta manera, la unidad final de análisis representa una transición y no una observación aislada.

El período utilizado para el análisis de las transiciones comienza en el cuarto trimestre de 2023 y se extiende hasta el primer trimestre de 2026. Esta delimitación se encuentra determinada por la disponibilidad de la información necesaria para identificar la condición de formalidad laboral durante el período analizado.

La muestra permite distinguir entre permanencia y movilidad dentro de dos estados de interés: empleo formal y empleo informal. En consecuencia, el análisis no busca modelar todos los posibles cambios en la situación laboral, sino específicamente los movimientos entre estos dos estados.

2.3. Identificación longitudinal

La dimensión longitudinal constituye un elemento central de la estrategia empírica. La identificación de una misma persona en períodos consecutivos se realiza mediante la combinación de los identificadores de vivienda, hogar y componente provistos por la EPH.

A partir del año y trimestre de cada observación se construye un identificador temporal que permite ordenar las observaciones y establecer la correspondencia entre períodos consecutivos. Si una persona es identificada en el período t y nuevamente en el período $t + 1$, ambas observaciones se vinculan para construir su transición laboral.

La estructura resultante permite representar la evolución de la condición de formalidad de cada individuo mediante una matriz de transición entre dos estados:

$$\begin{array}{c|cc}
 & Formal_{t+1} & Informal_{t+1} \\
 \hline
 Formal_t & Formal \rightarrow Formal & Formal \rightarrow Informal \\
 Informal_t & Informal \rightarrow Formal & Informal \rightarrow Informal
 \end{array} \quad (1)$$

Las celdas de la diagonal representan permanencia en el estado inicial, mientras que las celdas fuera de la diagonal representan movilidad entre formalidad e informalidad. Esta distinción permite analizar por separado los dos sentidos de la movilidad laboral.

2.4. Definición de las variables

El análisis se centra en dos tipos de variables: una variable de estado, utilizada para identificar la formalidad del empleo, y un conjunto de características individuales y laborales utilizadas para caracterizar las transiciones.

La condición de formalidad permite clasificar el empleo de cada individuo en dos estados: formal e informal. A partir de la comparación entre el estado observado en t y el observado en $t + 1$ se construyen las variables dependientes del análisis econométrico.

Para estudiar la movilidad en cada dirección se definen dos variables binarias. La primera corresponde a la transición formal–informal y toma el valor uno cuando un individuo formal en t se encuentra en un empleo informal en $t + 1$. La segunda corresponde a la transición informal–formal y toma el valor uno cuando un individuo informal en t pasa a un empleo formal en $t + 1$.

En ambos casos, las variables explicativas corresponden a características observadas en el período inicial t . Se consideran dimensiones individuales, como sexo, edad y nivel educativo, y características asociadas al empleo, como categoría ocupacional, horas trabajadas e ingreso laboral. También se incorpora la región de residencia como dimensión geográfica.

Esta definición temporal de las variables resulta relevante para la estrategia empírica: las características utilizadas para explicar una transición corresponden al período previo a la misma. Por lo tanto, el modelo relaciona las condiciones observadas en t con la ocurrencia de un cambio en la condición de formalidad entre t y $t + 1$.

2.5. Estrategia econométrica

La elección de la técnica econométrica surge directamente de la forma en que se plantea la pregunta de investigación. El objetivo no es explicar un nivel continuo de formalidad, sino analizar la probabilidad de que ocurra una transición determinada entre dos estados.

Una primera posibilidad sería considerar conjuntamente todos los estados laborales y estimar un modelo con múltiples categorías. Sin embargo, el interés de este trabajo está específicamente puesto en la movilidad entre formalidad e informalidad y, además, en distinguir los dos sentidos de dicha movilidad. Por este motivo, se plantean dos problemas de elección binaria independientes.

El primer modelo estudia la probabilidad de pasar de un empleo formal a uno informal:

$$P(FI_i = 1 \mid X_i) = \frac{\exp(X_i' \beta_{FI})}{1 + \exp(X_i' \beta_{FI})}, \quad (2)$$

donde $FI_i = 1$ indica que el individuo experimenta una transición de formalidad a informalidad entre t y $t + 1$.

El segundo modelo estudia la probabilidad de pasar de un empleo informal a uno formal:

$$P(IF_i = 1 | X_i) = \frac{\exp(X_i' \beta_{IF})}{1 + \exp(X_i' \beta_{IF})}, \quad (3)$$

donde $IF_i = 1$ indica que el individuo experimenta una transición de informalidad a formalidad entre t y $t + 1$.

La utilización de un modelo Logit resulta apropiada porque la variable dependiente de cada especificación es binaria y el interés se centra en modelar la probabilidad de ocurrencia de cada transición. Además, la estimación de modelos separados permite que los parámetros asociados a las características individuales y laborales sean diferentes para cada dirección de movilidad. Esto evita imponer, a priori, que los factores asociados con la salida de la formalidad sean los mismos que aquellos asociados con la entrada a ella.

La estrategia de estimación se complementa con el análisis de odds ratios y probabilidades predichas, que permiten facilitar la interpretación de los coeficientes del modelo. Asimismo, se evalúa la capacidad predictiva mediante diferentes métricas de clasificación y la curva ROC.

La muestra se divide en un conjunto de entrenamiento y un conjunto de evaluación, utilizando una proporción de 70 % y 30 %, respectivamente. La partición permite estimar los modelos sobre una parte de las observaciones y evaluar posteriormente su desempeño sobre datos no utilizados durante la estimación.

En todos los casos, el objetivo de la estimación es identificar asociaciones entre las características observadas en el período t y la probabilidad de experimentar una transición en $t + 1$. Los resultados no se interpretan como efectos causales, dado que la estrategia utilizada no permite controlar por todas las fuentes potenciales de heterogeneidad no observada ni establecer una relación causal entre las variables explicativas y las transiciones laborales.

3. Análisis exploratorio de los datos

El análisis exploratorio tiene como objetivo caracterizar la estructura de la base utilizada, evaluar la disponibilidad de las principales variables, identificar patrones de valores faltantes y describir las características individuales y laborales relevantes para el estudio de la movilidad entre formalidad e informalidad. En esta etapa también se examinan las relaciones bivariadas entre la condición de formalidad y las principales variables que serán consideradas posteriormente en los modelos de regresión logística.

3.1. Estructura y cobertura de la base

La base inicial se construye a partir de los microdatos individuales de la Encuesta Permanente de Hogares (EPH) para el período comprendido entre el primer trimestre de 2023 y el primer trimestre de 2026. En total, se dispone de 13 ondas trimestrales, con 604.906 observaciones individuales y 239 variables. La cobertura geográfica comprende las seis regiones estadísticas consideradas en la EPH y 32 aglomerados urbanos.

La cantidad de observaciones presenta variaciones entre los distintos trimestres, asociadas a la estructura propia de cada relevamiento. La distribución de las observaciones por región se presenta en la Figura 1.




Figura 1: Distribución de las observaciones por región

Un aspecto particularmente relevante para el objetivo de este trabajo es la disponibilidad de la variable EMPLEO, utilizada para identificar la formalidad laboral. La exploración de esta variable muestra que su disponibilidad para las personas ocupadas comienza en el cuarto trimestre de 2023. Por este motivo, si bien la base general comprende desde 2023T1, el análisis de formalidad y movilidad se restringe al período 2023T4–2026T1.

La Figura 2 muestra la disponibilidad de la variable de formalidad entre las personas ocupadas a lo largo de los períodos considerados.




Figura 2: Disponibilidad de la variable de formalidad por período

Esta restricción temporal resulta necesaria para garantizar que la variable utilizada para identificar formalidad e informalidad se encuentre disponible de manera comparable en los períodos utilizados para construir las transiciones longitudinales.

3.2. Valores faltantes y disponibilidad de información

Los microdatos de la EPH presentan valores faltantes en distintas variables, por lo que su tratamiento requiere considerar la estructura del cuestionario. En particular, varias variables laborales se relevan únicamente para determinados grupos de personas.

La Figura 3 presenta los valores faltantes de las principales variables seleccionadas para el análisis. La presencia de valores faltantes es especialmente relevante en aquellas variables vinculadas con las características de la ocupación.




Figura 3: Valores faltantes en las variables seleccionadas

Una característica importante es que la ausencia de información no debe interpretarse automáticamente como pérdida de datos. En varias variables laborales los valores faltantes responden a saltos estructurales del cuestionario: por ejemplo, determinadas características del puesto de trabajo solo son relevadas entre las personas ocupadas.

Esto se observa con mayor claridad en la variable **EMPLEO**. La Figura 4 muestra la proporción de valores faltantes de esta variable según la situación laboral.




Figura 4: Valores faltantes de la variable de formalidad según situación laboral

La concentración de valores faltantes fuera del universo de personas ocupadas es consistente con la definición de la variable, ya que la formalidad laboral solo resulta pertinente para quienes poseen una ocupación. En consecuencia, no se realiza una imputación general de estos valores. Posteriormente, cada variable se utiliza dentro del universo para el cual posee una interpretación económica y estadística válida.

3.3. Características generales de las personas ocupadas

Una vez delimitado el universo de análisis, se examinan las principales características individuales y laborales de las personas ocupadas. En primer lugar, la condición de formalidad se define a partir de la variable **EMPLEO**, considerando las categorías Formal e Informal y excluyendo los casos correspondientes a “Ns/Nr”.

La Figura 5 presenta la distribución general de las personas ocupadas según condición de formalidad.




Figura 5: Distribución de las personas ocupadas según formalidad laboral

La distribución temporal de esta variable se presenta en la Figura 6. El gráfico permite observar la composición de las personas ocupadas entre empleos formales e informales a lo largo de los períodos incluidos en la ventana de análisis.




Figura 6: Formalidad laboral por período

En términos generales, la composición de la ocupación según formalidad no presenta cambios abruptos entre períodos, lo que proporciona un contexto adecuado para el análisis posterior de las transiciones entre ambas situaciones.

Respecto de las características individuales, la distribución de la edad de las personas ocupadas se presenta en la Figura 7.




Figura 7: Distribución de la edad de las personas ocupadas

Asimismo, la distribución de la edad por período se presenta en la Figura 8. Esta representación permite verificar la estabilidad de la composición etaria de la población ocupada a lo largo de la ventana temporal.




Figura 8: Distribución de la edad de las personas ocupadas por período

En cuanto al sexo, la Figura 9 presenta la composición de las personas ocupadas según esta característica.




Figura 9: Distribución de las personas ocupadas por sexo

El nivel educativo constituye otra característica individual relevante para el análisis. La Figura 10 muestra la distribución de las personas ocupadas entre los distintos niveles educativos considerados.




Figura 10: Distribución de las personas ocupadas según nivel educativo

La distribución evidencia la heterogeneidad educativa existente dentro de la población ocupada, por lo que esta variable resulta pertinente para analizar si las características educativas se relacionan con la condición de formalidad y, posteriormente, con las transiciones entre formalidad e informalidad.

3.4. Características laborales

Además de las características individuales, se consideran variables relacionadas con las condiciones laborales. La primera corresponde a la categoría ocupacional. La Figura 11 muestra la composición de las personas ocupadas según esta clasificación.




Figura 11: Distribución de las personas ocupadas según categoría ocupacional

La distribución de las horas trabajadas en la ocupación principal se presenta en la Figura 12. Para este análisis se considera como rango válido el intervalo de 1 a 168 horas semanales. La visualización se limita a 120 horas en el eje horizontal para facilitar la lectura, manteniendo las observaciones restantes dentro del rango válido.




Figura 12: Distribución de las horas trabajadas en la ocupación principal

La distribución presenta una concentración de observaciones en niveles relativamente bajos y medios de horas trabajadas, junto con una cola hacia valores elevados. Esta característica justifica la revisión del rango válido de la variable antes de incorporarla a la estimación econométrica.

Finalmente, se analiza el ingreso laboral correspondiente a la ocupación principal, medido mediante la variable P21. La distribución del ingreso presenta una marcada asimetría, por lo que además de la representación en niveles se utiliza una transformación logarítmica únicamente con fines gráficos.




Figura 13: Distribución del ingreso laboral

La transformación logarítmica permite visualizar con mayor claridad la distribución completa del ingreso y su dispersión. Sin embargo, esta transformación se utiliza únicamente para la visualización exploratoria; en la especificación econométrica posterior el ingreso se incorpora expresado en miles de pesos.

3.5. Relaciones bivariadas con la formalidad laboral

Una segunda etapa del análisis exploratorio consiste en estudiar la relación descriptiva entre la formalidad laboral y las principales características individuales y laborales. Estos resultados permiten identificar patrones que serán considerados posteriormente en la especificación de los modelos logísticos. Las relaciones presentadas en esta sección son descriptivas y no deben interpretarse como relaciones causales.

En primer lugar, la Figura 14 presenta la composición de la formalidad laboral según sexo.




Figura 14: Formalidad laboral según sexo

La comparación muestra diferencias en la composición de formalidad entre varones y mujeres, aunque la magnitud de estas diferencias debe interpretarse como una asociación descriptiva sin controlar por otras características individuales o laborales.

Una relación más marcada se observa al considerar el nivel educativo. La Figura 15 presenta la composición de formalidad dentro de cada nivel educativo.




Figura 15: Formalidad laboral según nivel educativo

El gráfico muestra una asociación entre el nivel educativo y la composición entre empleos formales e informales. En particular, la participación relativa del empleo formal difiere entre los distintos niveles educativos, lo que motiva la inclusión de esta variable como covariable en los modelos posteriores.

La edad también presenta diferencias en su distribución según condición de formalidad. La Figura 16 compara ambas distribuciones mediante diagramas de caja.




Figura 16: Distribución de la edad según formalidad laboral

La comparación permite observar diferencias en la distribución etaria de las personas ocupadas según su condición de formalidad. Dado que la edad es una variable continua y puede presentar una relación no lineal con la probabilidad de transición, su comportamiento será considerado en la especificación del modelo.

La categoría ocupacional presenta asimismo una composición diferente según formalidad. La Figura 17 muestra la distribución de formalidad dentro de cada categoría ocupacional.




Figura 17: Formalidad laboral según categoría ocupacional

Las diferencias observadas justifican considerar la categoría ocupacional como una característica laboral relevante para el análisis de las transiciones.

Por su parte, el ingreso laboral presenta diferencias en su distribución según la condición de formalidad. La Figura 18 presenta esta comparación mediante diagramas de caja, con el ingreso

expresado en miles de pesos.




Figura 18: Distribución del ingreso laboral según formalidad

El gráfico muestra diferencias en la distribución del ingreso laboral entre personas ocupadas formales e informales. Esta variable se incorpora posteriormente al modelo, utilizando valores positivos y expresándola en miles de pesos para facilitar la interpretación de los coeficientes.

Finalmente, se analiza la dimensión geográfica. La Figura 19 presenta la composición de la formalidad laboral en las distintas regiones estadísticas.




Figura 19: Formalidad laboral según región

Se observan diferencias regionales en la composición entre formalidad e informalidad. Dado que estas diferencias pueden recoger características estructurales del mercado laboral regional, la región se incorpora como variable de control en las estimaciones posteriores.

En conjunto, el análisis exploratorio muestra heterogeneidad en la condición de formalidad según características individuales, laborales y geográficas. Estos patrones proporcionan una primera descripción de las diferencias observadas en la población ocupada y sirven como punto de partida para el análisis longitudinal de las transiciones entre formalidad e informalidad. No obstante, las relaciones descriptivas identificadas en esta sección no permiten establecer efectos causales, por lo que su interpretación se restringe a asociaciones observadas en los datos.

4. Movilidad entre formalidad e informalidad

Una vez caracterizada la estructura de la muestra y las principales características de las personas ocupadas, esta sección se concentra en el análisis de la movilidad entre formalidad e informalidad. El objetivo es identificar y describir los cambios en la condición de formalidad de una misma persona entre dos períodos consecutivos.

Para ello, se construyó una estructura longitudinal a partir de los microdatos de la EPH, que permite vincular las observaciones correspondientes a una misma persona en períodos sucesivos. El análisis se restringe a las personas que permanecen ocupadas en ambos períodos, de modo que las transiciones analizadas correspondan específicamente a movimientos entre un empleo formal y uno informal, y no a cambios desde el empleo hacia el desempleo o la inactividad.

4.1. Identificación longitudinal y construcción de las transiciones

La identificación de una misma persona a lo largo del tiempo se realizó utilizando conjuntamente las variables CODUSU, NRO_HOGAR y COMPONENTE. A partir de estas variables se vincularon las observaciones correspondientes a dos períodos consecutivos, definidos como t y $t + 1$.

La disponibilidad de la variable EMPLEO, utilizada para identificar la condición de formalidad, determinó que la construcción de las transiciones se realizara a partir del cuarto trimestre de 2023. Por lo tanto, la base longitudinal utilizada para este análisis abarca el período comprendido entre el cuarto trimestre de 2023 y el primer trimestre de 2026, generando nueve posibles transiciones entre períodos consecutivos.

La unidad de análisis en esta sección es, por lo tanto, la *persona-transición*. Cada observación representa la situación laboral de una persona en un período inicial t y su situación en el período inmediatamente posterior $t + 1$.

Para concentrar el análisis en la movilidad entre formalidad e informalidad, se consideraron únicamente las personas que se encontraban ocupadas en ambos períodos:

$$ESTADO_t = 1 \quad \text{y} \quad ESTADO_{t+1} = 1. \quad (4)$$

Asimismo, se conservaron únicamente aquellas observaciones con información válida de la variable EMPLEO en ambos períodos. De esta manera, una transición desde un empleo formal hacia el desempleo o la inactividad no se considera una transición Formal-Informal, dado que implica un cambio en la condición de actividad y no exclusivamente en la condición de formalidad.

4.2. Definición de los tipos de movilidad

A partir de la condición de formalidad observada en t y $t + 1$ se identificaron cuatro posibles situaciones:

- Formal $\rightarrow$ Formal: la persona permanece en un empleo formal.

- Formal $\rightarrow$ Informal: la persona pasa de un empleo formal a uno informal.
- Informal $\rightarrow$ Formal: la persona pasa de un empleo informal a uno formal.
- Informal $\rightarrow$ Informal: la persona permanece en un empleo informal.

De estas cuatro situaciones, las dos primeras permiten caracterizar la persistencia o salida de la formalidad, mientras que las dos últimas permiten analizar la persistencia o entrada a la formalidad.

El interés principal se encuentra en las dos transiciones que implican un cambio de estado:

$$Formal \rightarrow Informal \quad (5)$$

y

$$Informal \rightarrow Formal. \quad (6)$$

Esta distinción resulta central para el análisis posterior, ya que ambos movimientos representan fenómenos diferentes. La primera transición caracteriza una salida de la formalidad, mientras que la segunda representa una entrada a la formalidad. Por este motivo, en la sección siguiente se analizarán mediante dos modelos Logit separados.

4.3. Matriz de transición

La matriz de transición permite observar conjuntamente la condición de formalidad de las personas en dos períodos consecutivos y distinguir entre permanencia y movilidad.

La Figura 20 presenta gráficamente la distribución de las cuatro posibles transiciones identificadas en la muestra longitudinal. Como puede observarse, las situaciones de permanencia presentan una frecuencia considerablemente mayor que las transiciones entre estados.




Figura 20: Matriz de transición entre formalidad e informalidad.

Fuente: elaboración propia con base en microdatos de la EPH.

En particular, se identificaron 37.157 transiciones Formal $\rightarrow$ Formal y 24.121 transiciones Informal $\rightarrow$ Informal. En comparación, las transiciones que implican un cambio de condición fueron menos

frecuentes: se registraron 3.669 movimientos Formal $\rightarrow$ Informal y 3.612 movimientos Informal $\rightarrow$ Formal.

Considerando la situación inicial de cada persona, aproximadamente el 91% de quienes se encontraban en un empleo formal permanecieron en la formalidad en el período siguiente, mientras que cerca del 9% transitó hacia un empleo informal. Entre quienes inicialmente se encontraban en un empleo informal, alrededor del 87% permaneció en dicha condición y aproximadamente el 13% transitó hacia un empleo formal.

La Figura 20 permite observar, por lo tanto, que la característica predominante de la movilidad laboral durante el período analizado es la persistencia de la condición inicial. Al mismo tiempo, la existencia de movimientos en ambas direcciones muestra que la movilidad entre formalidad e informalidad no constituye un fenómeno unidireccional.

4.4. Evolución temporal de las transiciones

La matriz anterior resume conjuntamente todo el período de análisis. Sin embargo, una medida agregada puede ocultar diferencias entre los distintos períodos. Por este motivo, se examinó también la evolución temporal de las tasas de transición.

Para las personas inicialmente formales, la tasa de transición hacia la informalidad se definió como:

$$T_{FI,t} = \frac{N(\text{Formal}_t \rightarrow \text{Informal}_{t+1})}{N(\text{Formal}_t \rightarrow \text{Formal}_{t+1}) + N(\text{Formal}_t \rightarrow \text{Informal}_{t+1})}. \quad (7)$$

Esta medida representa la proporción de personas que, encontrándose formalizadas en el período t , pasan a un empleo informal en el período siguiente.

De manera análoga, para las personas inicialmente informales se definió la tasa de transición hacia la formalidad como:

$$T_{IF,t} = \frac{N(\text{Informal}_t \rightarrow \text{Formal}_{t+1})}{N(\text{Informal}_t \rightarrow \text{Formal}_{t+1}) + N(\text{Informal}_t \rightarrow \text{Informal}_{t+1})}. \quad (8)$$

La Figura 21 presenta la evolución de ambas tasas a lo largo de los períodos disponibles.




Figura 21: Evolución de las tasas de transición entre formalidad e informalidad.

Fuente: elaboración propia con base en microdatos de la EPH.

La Figura 21 permite analizar por separado la salida de la formalidad y la entrada a ella. Esta distinción es relevante porque las dos tasas tienen denominadores diferentes y, por lo tanto, no deben interpretarse como dos componentes de una única tasa de movilidad.

Asimismo, la evolución temporal permite observar si los movimientos entre ambos estados presentan un comportamiento relativamente estable a lo largo del período o si existen trimestres en los cuales alguna de las transiciones adquiere una mayor presencia relativa.

El análisis temporal tiene además una función descriptiva dentro del trabajo: permite verificar que la movilidad observada en el conjunto de la muestra no responda exclusivamente a un único período. La variación entre trimestres será considerada como parte del contexto en el que se estiman posteriormente los modelos de probabilidad.

4.5. Caracterización de las personas que experimentan movilidad

Una vez identificadas las transiciones, se realizó una caracterización descriptiva de las personas que efectivamente experimentaron un cambio en su condición de formalidad.

A diferencia del análisis de la matriz de transición, en este caso se consideran exclusivamente las personas que cambiaron de estado, es decir, aquellas que realizaron una transición Formal → Informal o Informal → Formal.

El objetivo es analizar la composición de estos dos grupos de personas según diferentes características individuales y laborales. En particular, se consideran la categoría ocupacional, el sexo, el nivel educativo, la edad y el ingreso laboral.

Es importante señalar que los gráficos de esta sección muestran la *composición de las personas que experimentaron movilidad* y no la probabilidad de transición de cada categoría. Por lo tanto, las diferencias observadas deben interpretarse como patrones descriptivos y no como efectos de las características consideradas sobre la movilidad.

4.5.1. Categoría ocupacional

La primera dimensión considerada es la categoría ocupacional. La Figura 22 presenta la composición de las personas que experimentaron cada tipo de transición según su categoría ocupacional.




Figura 22: Composición de las personas que experimentan movilidad según categoría ocupacional.

Fuente: elaboración propia con base en microdatos de la EPH.

Como muestra la Figura 22, la composición ocupacional de las personas que transitan entre formalidad e informalidad no es necesariamente idéntica en ambas direcciones. El gráfico permite identificar qué categorías ocupacionales tienen una mayor presencia relativa entre quienes experimentan cada tipo de movimiento.

Estos resultados constituyen una primera aproximación descriptiva a la relación entre las características del empleo y la movilidad. La categoría ocupacional será posteriormente incorporada al análisis multivariado para evaluar su asociación con la probabilidad de transición una vez consideradas simultáneamente las restantes características.

4.5.2. Sexo

La Figura 23 presenta la composición por sexo de las personas que experimentaron movilidad entre formalidad e informalidad.




Figura 23: Composición por sexo de las personas que experimentan movilidad.

Fuente: elaboración propia con base en microdatos de la EPH.

La Figura 23 permite comparar la participación relativa de varones y mujeres entre quienes realizan una transición Formal $\rightarrow$ Informal y quienes realizan una transición Informal $\rightarrow$ Formal. De esta manera, el gráfico permite identificar diferencias en la composición de ambos grupos de movilidad.

La información presentada no permite, por sí sola, determinar si el sexo está asociado con una mayor probabilidad de experimentar una transición, ya que para ello sería necesario considerar también la composición de la población inicialmente formal o informal y controlar por otras características. Esta cuestión será abordada mediante los modelos estimados en la siguiente sección.

4.5.3. Nivel educativo

El nivel educativo constituye otra dimensión relevante para caracterizar a las personas que experimentan movilidad. La Figura 24 presenta la composición educativa de los dos grupos de transición.




Figura 24: Composición educativa de las personas que experimentan movilidad.

Fuente: elaboración propia con base en microdatos de la EPH.

La Figura 24 permite observar la distribución de los distintos niveles educativos entre quienes pasan de la formalidad a la informalidad y quienes realizan el movimiento inverso. El gráfico permite así identificar diferencias en la composición educativa de ambos tipos de movilidad.

Estas diferencias descriptivas constituyen un punto de partida para el análisis econométrico. En particular, el nivel educativo será incluido como una variable categórica en los modelos, permitiendo evaluar su asociación con la probabilidad de experimentar cada tipo de transición manteniendo constantes las demás variables incluidas en la especificación.

4.5.4. Edad

Para analizar la edad se utilizó un diagrama de cajas, que permite comparar simultáneamente la posición central, la dispersión y los valores extremos de esta variable entre los dos tipos de movilidad.




Figura 25: Distribución de la edad entre las personas que experimentan movilidad.

Fuente: elaboración propia con base en microdatos de la EPH.

Como se observa en la Figura 25, la distribución de la edad puede compararse entre las personas que realizan una transición Formal $\rightarrow$ Informal y aquellas que realizan una transición Informal $\rightarrow$ Formal. La utilización del diagrama de cajas permite, además, observar la dispersión de las edades dentro de cada grupo y la presencia de observaciones alejadas de la distribución central.

En el análisis econométrico, la edad se incorpora como una variable continua medida en años, de manera que su relación con la probabilidad de transición pueda ser evaluada conjuntamente con las demás características individuales y laborales.

4.5.5. Ingreso laboral

Finalmente, se analizó el ingreso laboral de las personas que experimentaron movilidad. Debido a la elevada dispersión que caracteriza a esta variable, se utilizó un diagrama de cajas para facilitar la comparación entre ambos tipos de transición.




Figura 26: Distribución del ingreso laboral entre las personas que experimentan movilidad.

Fuente: elaboración propia con base en microdatos de la EPH.

La Figura 26 permite comparar la distribución del ingreso laboral entre las personas que transitan desde la formalidad hacia la informalidad y aquellas que realizan el movimiento inverso. El gráfico permite observar diferencias tanto en la posición central como en la dispersión de los ingresos dentro de cada grupo.

Para facilitar su interpretación posterior, el ingreso se expresa en miles de pesos en la especificación econométrica. Las diferencias observadas en esta etapa deben interpretarse nuevamente como patrones descriptivos, ya que la distribución del ingreso puede estar asociada simultáneamente con otras características individuales y laborales.

4.6. Síntesis de los patrones de movilidad

El análisis desarrollado en esta sección permite caracterizar la movilidad entre formalidad e informalidad desde diferentes perspectivas. En primer lugar, la matriz de transición presentada en la Figura 20 muestra que la permanencia en la condición inicial es considerablemente más frecuente que el cambio de estado. Esto ocurre tanto entre las personas inicialmente formales como entre aquellas inicialmente informales.

En segundo lugar, la evolución temporal presentada en la Figura 21 permite distinguir la dinámica de las dos direcciones de movilidad a lo largo del período analizado, evitando reducir el fenómeno a una única medida agregada.

Por último, las Figuras 22, 23, 24, 25 y 26 permiten caracterizar a las personas que efectivamente experimentaron movilidad según diferentes dimensiones individuales y laborales.

En conjunto, estos resultados descriptivos muestran que la movilidad entre formalidad e informalidad puede analizarse como dos fenómenos diferenciados: la salida de un empleo formal hacia uno informal y la entrada desde un empleo informal hacia uno formal. Esta distinción constituye la base para la estrategia econométrica desarrollada en la siguiente sección.

En particular, la existencia de diferencias descriptivas entre los grupos de movilidad no permite establecer, por sí misma, qué características están asociadas con una mayor probabilidad de transición.

Para responder esta cuestión es necesario considerar simultáneamente las distintas características individuales y laborales. Por este motivo, la Sección 5 presenta la estimación de dos modelos Logit independientes, uno para cada dirección de movilidad.

5. Modelización de la movilidad entre formalidad e informalidad

Con el objetivo de analizar qué características individuales y laborales se encuentran asociadas con las transiciones entre formalidad e informalidad, se estiman dos modelos de regresión logística binaria. La estrategia consiste en separar los dos sentidos de la movilidad laboral, dado que los factores asociados a una salida desde un empleo formal hacia uno informal no necesariamente coinciden con aquellos relacionados con una transición desde la informalidad hacia la formalidad.

5.1. Especificación de los modelos

Se estiman dos modelos Logit independientes. El primero considera como variable dependiente una indicadora que toma el valor uno cuando una persona que se encontraba en un empleo formal en el período t pasa a un empleo informal en el período $t + 1$, y cero cuando permanece en la formalidad.

El segundo modelo considera como evento de interés la transición inversa: toma el valor uno cuando una persona que se encontraba en un empleo informal en t pasa a un empleo formal en $t + 1$, y cero cuando permanece en la informalidad.

En ambos casos, las variables explicativas corresponden a características observadas en el período inicial t . La especificación incluye sexo, edad, nivel educativo, categoría ocupacional, horas trabajadas, ingreso laboral y región de residencia. De esta manera, el modelo busca identificar asociaciones entre estas características y la probabilidad de experimentar cada tipo de transición.

Formalmente, para cada transición se estima:

$$P(Y_i = 1 \mid X_i) = \frac{\exp(X_i' \beta)}{1 + \exp(X_i' \beta)}, \quad (9)$$

donde Y_i representa la ocurrencia de la transición analizada y X_i contiene el conjunto de características individuales y laborales observadas en el período inicial.

La muestra utilizada para la estimación se divide aleatoriamente en un conjunto de entrenamiento del 70 % y un conjunto de prueba del 30 %. La división se realiza utilizando una semilla fija (2026), con el objetivo de garantizar la reproducibilidad de los resultados.

5.2. Distribución de las variables dependientes

La distribución de las variables dependientes evidencia un desbalance entre las observaciones correspondientes a transiciones y aquellas que no experimentan el movimiento analizado.

En el modelo de *Formal* $\rightarrow$ *Informal*, se dispone de 30.498 observaciones, de las cuales 27.718 corresponden a permanencia en la formalidad y 2.780 a una transición hacia la informalidad. Por lo tanto, la transición de interés representa el 8,83 % de la muestra.

En el modelo de *Informal* $\rightarrow$ *Formal*, se dispone de 21.970 observaciones. De ellas, 19.282 corresponden a permanencia en la informalidad y 2.688 a una transición hacia la formalidad, representando el 12,23 % de las observaciones.

Cuadro 1: Distribución de las variables dependientes

Modelo	$Y = 0$	$Y = 1$	% de casos $Y = 1$
Formal $\rightarrow$ Informal	27.718	2.780	8,83 %
Informal $\rightarrow$ Formal	19.282	2.688	12,23 %

Este desbalance resulta relevante para la evaluación de los modelos. En particular, una regla de clasificación que predijera sistemáticamente la categoría mayoritaria podría alcanzar una accuracy elevada sin detectar adecuadamente las transiciones de interés. Por este motivo, además de la accuracy se consideran la sensibilidad, la especificidad, la precisión, el F1 y la balanced accuracy.

5.3. Resultados de los modelos Logit

Los resultados se presentan mediante *odds ratios* (OR), que permiten interpretar los coeficientes del modelo en términos multiplicativos sobre las chances relativas de experimentar la transición analizada. Un OR superior a uno indica mayores *odds* del evento respecto de la categoría de referencia, mientras que un OR inferior a uno indica menores *odds*. Las interpretaciones corresponden a asociaciones condicionales al resto de las variables incluidas en el modelo y no deben interpretarse como efectos causales.

5.3.1. Transición Formal $\rightarrow$ Informal

Los resultados del primer modelo muestran asociaciones estadísticamente significativas para varias de las características consideradas.

El sexo presenta una asociación significativa con la transición. En particular, el OR correspondiente a las mujeres es 1,174 ($p = 0,0027$), lo que indica que, manteniendo constantes las restantes variables del modelo, las *odds* de pasar de un empleo formal a uno informal son aproximadamente un 17,4 % mayores para las mujeres respecto de los varones.

La edad presenta un OR de 0,9716 ($p < 0,001$). Por lo tanto, un incremento de un año de edad se encuentra asociado con una reducción aproximada del 2,84 % en las *odds* de realizar una transición desde la formalidad hacia la informalidad, manteniendo constantes las demás variables.

El nivel educativo presenta una relación particularmente marcada. Tomando como categoría de referencia el nivel de educación primario incompleto, no se encuentran diferencias estadísticamente significativas para primario completo ni para secundario incompleto. En cambio, las personas con secundario completo presentan un OR de 0,5014, mientras que aquellas con educación superior o universitaria incompleta presentan un OR de 0,3728 y aquellas con educación superior o universitaria completa un OR de 0,2326. Estos resultados indican una asociación negativa entre niveles educativos más elevados y la transición desde la formalidad hacia la informalidad.

La categoría ocupacional también presenta diferencias relevantes. Respecto de la categoría ocupacional utilizada como referencia, el OR para los trabajadores por cuenta propia es 1,4156 ($p = 0,0027$), mientras que para obreros o empleados es 0,2407 ($p < 0,001$). Por lo tanto, dentro de la especificación estimada, la categoría ocupacional se encuentra fuertemente asociada con la probabilidad de experimentar una salida desde la formalidad.

Las horas trabajadas presentan un OR de 0,9903 ($p < 0,001$). Esto implica que una hora adicional de trabajo se encuentra asociada con una reducción aproximada del 0,97 % en las *odds* de transición hacia la informalidad.

El ingreso laboral también presenta una asociación estadísticamente significativa. El OR es 0,99945 por cada \$1.000 adicionales de ingreso laboral ($p < 0,001$). Debido a que el efecto se mide por

incrementos de \$1.000, el valor del OR se encuentra muy próximo a uno; sin embargo, la dirección de la asociación es negativa.

Finalmente, se observan diferencias regionales. En comparación con la región de referencia, la región Pampeana presenta un OR de 0,8261 ($p = 0,0145$), mientras que Patagonia presenta un OR de 0,6324 ($p < 0,001$). Para Noroeste, Noreste y Cuyo, los intervalos de confianza incluyen el valor uno, por lo que no se observan diferencias estadísticamente significativas al nivel convencional del 5 %.

La Figura 27 resume gráficamente estos resultados. La línea vertical en uno representa el punto de referencia para la interpretación de los *odds ratios*.




Figura 27: Odds ratios del modelo Formal → Informal

5.3.2. Transición Informal → Formal

El segundo modelo presenta un patrón diferente. En este caso, el nivel educativo adquiere especial relevancia y se observan asociaciones positivas entre mayores niveles educativos y la transición hacia la formalidad.

El OR asociado al sexo femenino es 0,9317 y no resulta estadísticamente significativo ($p = 0,1965$). Por lo tanto, una vez controladas las demás características incluidas en el modelo, no se encuentra evidencia estadísticamente significativa de una diferencia entre mujeres y varones en las *odds* de pasar desde la informalidad hacia la formalidad.

La edad presenta un OR de 1,0139 ($p < 0,001$). Esto implica que un año adicional de edad se encuentra asociado con un incremento aproximado del 1,39 % en las *odds* de transición hacia la formalidad.

El nivel educativo presenta una asociación positiva y creciente. Respecto de la categoría de referencia, el OR es 1,4198 para primario completo, 1,9133 para secundario incompleto, 3,2120 para secundario completo, 4,1137 para superior o universitario incompleto y 5,9903 para superior o universitario completo. Con excepción del resultado para primario completo, que se encuentra en el límite

del nivel convencional del 5 %, los coeficientes correspondientes a los niveles educativos superiores presentan asociaciones estadísticamente significativas.

En particular, el OR de 5,9903 asociado a educación superior o universitaria completa indica que, manteniendo constantes las demás variables, las *odds* de pasar desde la informalidad hacia la formalidad son aproximadamente seis veces las correspondientes a la categoría educativa de referencia.

La categoría ocupacional presenta también una asociación diferenciada. El OR para trabajadores por cuenta propia es 0,6711 ($p = 0,0086$), mientras que para obreros o empleados es 0,8797 y no resulta estadísticamente significativo ($p = 0,3902$).

Las horas trabajadas presentan un OR de 1,0060 ($p < 0,001$), por lo que una hora adicional se encuentra asociada con un incremento aproximado del 0,60 % en las *odds* de transición hacia la formalidad.

El ingreso laboral presenta un OR de 1,00046 por cada \$1.000 adicionales ($p < 0,001$). Al igual que en el modelo anterior, la magnitud del OR por \$1.000 es pequeña y debe interpretarse teniendo en cuenta la unidad de medición.

También se observan diferencias regionales. La región Noroeste presenta un OR de 0,6653 ($p < 0,001$), mientras que Patagonia presenta un OR de 1,4353 ($p < 0,001$). Para Noreste, Cuyo y Pampeana los intervalos de confianza incluyen el valor uno, por lo que no se encuentran diferencias estadísticamente significativas respecto de la región de referencia al nivel del 5 %.

Estos resultados se presentan gráficamente en la Figura 28.




Figura 28: Odds ratios del modelo Informal → Formal

5.4. Síntesis de los principales resultados de los modelos

La Tabla 2 resume los principales *odds ratios* obtenidos para las variables que presentan asociaciones estadísticamente significativas o resultan especialmente relevantes para la interpretación económica del fenómeno.

Cuadro 2: Principales resultados de los modelos Logit

Variable	Formal $\rightarrow$ Informal	Informal $\rightarrow$ Formal
Mujer	1,174	0,932
Edad	0,972	1,014
Secundario completo	0,501	3,212
Superior/univ. incompleto	0,373	4,114
Superior/univ. completo	0,233	5,990
Cuenta propia	1,416	0,671
Obrero o empleado	0,241	0,880
Horas trabajadas	0,990	1,006
Ingreso (+\$1.000)	0,99945	1,00046
Noroeste	0,871	0,665
Pampeana	0,826	1,075
Patagonia	0,632	1,435

Nota: Los valores corresponden a odds ratios condicionados al resto de las variables del modelo. Las categorías de referencia corresponden a las utilizadas en la especificación estimada. La tabla completa con intervalos de confianza y valores- p se presenta en el Anexo.

En conjunto, los resultados muestran que los dos sentidos de la movilidad presentan patrones diferenciados. La educación aparece asociada en ambos modelos, pero con direcciones opuestas: los niveles educativos superiores se relacionan con menores *odds* de pasar de la formalidad a la informalidad y con mayores *odds* de pasar de la informalidad a la formalidad. Esto constituye uno de los resultados más marcados de la estimación.

También se observa un comportamiento diferenciado de la edad: mientras que una mayor edad se asocia con menores *odds* de transición hacia la informalidad, se relaciona con mayores *odds* de transición hacia la formalidad. Las horas trabajadas presentan igualmente signos opuestos en ambos modelos.

Estos resultados deben interpretarse como asociaciones condicionales y no como efectos causales. En particular, pueden existir características no observadas de los trabajadores, de los puestos de trabajo o de los establecimientos que estén correlacionadas tanto con las variables explicativas como con las transiciones observadas.

5.5. Distribución de las probabilidades predichas

Además del análisis de los coeficientes, se examina la distribución de las probabilidades predichas por ambos modelos. La Figura 29 muestra que las probabilidades estimadas se concentran principalmente en valores bajos, tanto para la transición Formal $\rightarrow$ Informal como para Informal $\rightarrow$ Formal.

La línea vertical representa el umbral convencional de 0,5. La gran concentración de observaciones por debajo de este valor permite visualizar el motivo por el cual una regla de clasificación basada directamente en 0,5 resulta poco adecuada para detectar las transiciones de interés.




Figura 29: Distribución de las probabilidades predichas

5.6. Evaluación de la capacidad discriminatoria

La capacidad de discriminación de los modelos se evalúa mediante curvas ROC y el área bajo la curva (AUC). La AUC toma valores entre cero y uno y resume la capacidad del modelo para ordenar las observaciones según su probabilidad estimada de pertenecer a la clase positiva.

Para el modelo Formal $\rightarrow$ Informal, la AUC es de **0,7562**, mientras que para el modelo Informal $\rightarrow$ Formal alcanza **0,6736**. Estos valores indican que las probabilidades predichas contienen información para discriminar entre quienes realizan y quienes no realizan la transición, aunque la capacidad de discriminación difiere entre ambos modelos.

Cuadro 3: Área bajo la curva ROC

Modelo	AUC
Formal $\rightarrow$ Informal	0,7562
Informal $\rightarrow$ Formal	0,6736

Las curvas ROC correspondientes se presentan en las Figuras 30 y 31.




Figura 30: Curva ROC: Formal $\rightarrow$ Informal




Figura 31: Curva ROC: Informal $\rightarrow$ Formal

5.7. Evaluación de la clasificación y selección del umbral

Dado el desbalance de las variables dependientes, no resulta suficiente evaluar los modelos utilizando únicamente el umbral convencional de 0,5. Por este motivo se analizan distintos puntos de corte y se selecciona, para cada modelo, el umbral que maximiza el indicador F1 en el conjunto de prueba.

El estadístico F1 combina precisión y sensibilidad, por lo que resulta especialmente útil cuando la clase positiva representa una proporción minoritaria de las observaciones.

Para el modelo Formal $\rightarrow$ Informal, el valor máximo de F1 se alcanza con un umbral de **0,14**, mientras que para Informal $\rightarrow$ Formal el umbral óptimo es **0,17**.

Cuadro 4: Umbrales óptimos según el criterio F1

Modelo	Umbral óptimo
Formal $\rightarrow$ Informal	0,14
Informal $\rightarrow$ Formal	0,17

Las Figuras 32 y 33 muestran la evolución del F1 para los distintos umbrales evaluados y permiten observar los puntos en los cuales se alcanza el máximo.




Figura 32: F1 según el umbral de clasificación: Formal $\rightarrow$ Informal




Figura 33: F1 según el umbral de clasificación: Informal $\rightarrow$ Formal

5.8. Comparación entre el umbral convencional y el umbral óptimo

La Tabla 5 compara las métricas obtenidas con el umbral convencional de 0,5 y con el umbral seleccionado mediante la maximización del F1.

Cuadro 5: Evaluación de la clasificación según el umbral

Modelo	Umbral	Accuracy	Precision	Sensibilidad	Especificidad	F1	Balanced Accuracy
Formal $\rightarrow$ Informal	0,50	0,912	0,529	0,022	0,998	0,042	0,510
Formal $\rightarrow$ Informal	0,14	0,838	0,260	0,461	0,874	0,333	0,667
Informal $\rightarrow$ Formal	0,50	0,872	0,429	0,007	0,999	0,014	0,503
Informal $\rightarrow$ Formal	0,17	0,792	0,272	0,374	0,853	0,315	0,614

La comparación evidencia una diferencia importante entre evaluar el modelo con el umbral convencional y hacerlo con los puntos de corte seleccionados según F1. Para Formal $\rightarrow$ Informal, utilizar un umbral de 0,5 produce una accuracy de 0,912, pero la sensibilidad es solamente 0,0217. Esto significa que el modelo identifica correctamente una proporción muy reducida de las personas que efectivamente realizan la transición. Al reducir el umbral a 0,14, la sensibilidad aumenta hasta 0,461 y la balanced accuracy pasa de 0,510 a 0,667. El F1 también aumenta desde 0,042 hasta 0,333.

Para Informal $\rightarrow$ Formal se observa un comportamiento similar. Con el umbral de 0,5, la sensibilidad es solamente 0,0071 y el F1 alcanza 0,014. Al utilizar el umbral de 0,17, la sensibilidad aumenta hasta 0,374, mientras que la balanced accuracy pasa de 0,503 a 0,614 y el F1 alcanza 0,315.

El costo de esta modificación es una reducción de la especificidad y de la accuracy. Por lo tanto, la elección del punto de corte modifica el equilibrio entre la detección de las transiciones y la identificación correcta de quienes no las experimentan. En este trabajo, la selección de los umbrales de 0,14 y 0,17 se realiza específicamente bajo el criterio de maximizar el F1, por lo que no debe interpretarse como un umbral universal para la clasificación de la movilidad laboral.

5.9. Matrices de confusión

Las matrices de confusión permiten observar con mayor detalle los errores de clasificación. Con los umbrales seleccionados, el modelo Formal $\rightarrow$ Informal identifica correctamente 382 de las 829 transiciones observadas en el conjunto de prueba, mientras que clasifica incorrectamente 447 de ellas. Entre las observaciones que no realizan la transición, 7.535 son correctamente identificadas y 1.086 son clasificadas como positivas.

En el modelo Informal $\rightarrow$ Formal, se identifican correctamente 315 de las 842 transiciones positivas del conjunto de prueba, mientras que 527 son clasificadas incorrectamente como permanencias en la informalidad. Entre las observaciones negativas, 4.906 son correctamente clasificadas y 844 son falsos positivos.

Estos resultados muestran que la utilización de los umbrales óptimos mejora la detección de las transiciones respecto del umbral convencional, aunque persiste un número considerable de falsos positivos y falsos negativos. Esto es consistente con el carácter desbalanceado de las variables dependientes.

5.10. Síntesis e interpretación de los resultados

Los resultados de los modelos muestran que la movilidad entre formalidad e informalidad no presenta un patrón simétrico. Las características asociadas con la salida desde la formalidad son diferentes de aquellas asociadas con la entrada hacia la formalidad.

Entre los resultados más destacados se encuentra el papel del nivel educativo. Los niveles educativos superiores presentan menores *odds* de transición Formal $\rightarrow$ Informal y, simultáneamente, mayores *odds* de transición Informal $\rightarrow$ Formal. La magnitud de esta asociación aumenta con el nivel educativo en el segundo modelo.

La edad también presenta una relación diferenciada según el sentido de la transición. Una mayor edad se asocia con menores *odds* de salida hacia la informalidad y mayores *odds* de entrada a la formalidad. La categoría ocupacional muestra igualmente diferencias entre ambos procesos, especialmente en el caso de los trabajadores por cuenta propia.

Por otra parte, las variables de horas trabajadas e ingreso laboral presentan asociaciones estadísticamente significativas en ambos modelos, aunque con signos opuestos. Esto sugiere que las condiciones laborales observadas en el período inicial están relacionadas con la dirección de la movilidad posterior.

Finalmente, los indicadores de desempeño muestran que los modelos poseen capacidad discriminativa, aunque la detección de las transiciones positivas continúa siendo un desafío. El análisis del F1 evidencia que el umbral convencional de 0,5 es poco apropiado para este problema debido al desbalance de clases. La utilización de puntos de corte más bajos permite incrementar sustancialmente la sensibilidad y mejorar la balanced accuracy, aunque a costa de una menor especificidad.

En consecuencia, los resultados permiten caracterizar asociaciones sistemáticas entre las características individuales y laborales observadas en t y la movilidad entre formalidad e informalidad en $t + 1$, pero no permiten establecer relaciones causales. La interpretación debe considerar además que la capacidad predictiva es moderada y que una proporción importante de las transiciones no es correctamente identificada por los modelos.

6. Limitaciones

El análisis presentado permite caracterizar las transiciones entre formalidad e informalidad y estudiar su asociación con un conjunto de características individuales y laborales. Sin embargo, los

resultados deben interpretarse considerando algunas limitaciones vinculadas con la fuente de información, la construcción longitudinal y la estrategia econométrica utilizada.

En primer lugar, la EPH no constituye un panel permanente de individuos. La identificación longitudinal se construye vinculando las observaciones de una misma persona entre períodos consecutivos mediante los identificadores disponibles en la encuesta. Por lo tanto, el análisis permite estudiar las transiciones observadas entre ondas, pero no seguir de manera continua a todos los individuos durante todo el período de estudio. Además, pueden existir pérdidas de seguimiento entre períodos, lo que reduce la cantidad de observaciones disponibles para el análisis de movilidad.

En segundo lugar, la medición de la formalidad e informalidad depende de la información disponible en la EPH y de los criterios utilizados para construir la variable EMPLEO. Por lo tanto, la clasificación refleja la definición operacional adoptada en la base y puede no capturar completamente todas las dimensiones de la informalidad laboral. En particular, la informalidad constituye un fenómeno multidimensional que puede involucrar características del puesto de trabajo, de la relación laboral y del acceso a la seguridad social.

Una tercera limitación se relaciona con la presencia de valores faltantes y respuestas no informadas. La EPH presenta valores faltantes que, en buena medida, responden a la propia estructura del cuestionario y a los saltos correspondientes a personas que no se encuentran en determinadas situaciones laborales. En la preparación de las bases de modelización se aplicaron filtros sobre las variables utilizadas y se trabajó con observaciones completas para la estimación. Esta decisión permite obtener una base consistente para los modelos, pero puede reducir el tamaño muestral y generar diferencias entre la muestra inicial y la muestra finalmente utilizada.

En cuarto lugar, los modelos estimados corresponden a regresiones logísticas y, por lo tanto, identifican asociaciones condicionales y no efectos causales. La inclusión de sexo, edad, educación, categoría ocupacional, horas trabajadas, ingreso y región permite controlar por un conjunto relevante de características observables, pero pueden existir factores no observados relacionados simultáneamente con las características laborales y con la probabilidad de transición. Por esta razón, los odds ratios estimados no deben interpretarse como efectos causales de las variables explicativas sobre la movilidad laboral.

Una quinta limitación corresponde a la especificación funcional de los modelos. Las variables cuantitativas, como edad, horas trabajadas e ingreso laboral, se incorporan de manera lineal en el predictor logit. Esta especificación supone una relación determinada entre estas variables y el logaritmo de las odds de transición. Es posible que algunas de estas relaciones sean no lineales o presenten efectos diferenciados según distintos rangos de edad, ingresos u horas trabajadas. El presente trabajo mantiene una especificación parsimoniosa y no explora formas funcionales alternativas.

Asimismo, la información disponible no permite incorporar todas las características potencialmente relevantes de los puestos de trabajo, empresas y trayectorias laborales. Variables como estabilidad laboral, antigüedad, características específicas del establecimiento o condiciones institucionales pueden contribuir a explicar la movilidad, pero su disponibilidad, calidad o comparabilidad a lo largo de las ondas consideradas puede limitar su incorporación al modelo.

Otra limitación está relacionada con el uso de las ponderaciones muestrales. Las ponderaciones de la EPH son relevantes para obtener estimaciones descriptivas representativas de la población objetivo. En la estimación de los modelos Logit se trabajó sin ponderar, siguiendo la estrategia metodológica adoptada en el trabajo práctico. En consecuencia, los resultados econométricos deben interpretarse como asociaciones estimadas sobre la muestra analítica y no directamente como estimaciones poblacionales ponderadas.

Finalmente, el análisis predictivo presenta una limitación derivada del desbalance de las clases. Las transiciones de interés representan una proporción minoritaria de las observaciones, especial-

mente en el caso Formal $\rightarrow$ Informal. Como consecuencia, el umbral convencional de 0,5 genera una sensibilidad muy baja. Para abordar este problema se seleccionaron umbrales alternativos mediante la maximización del indicador F1, obteniéndose puntos de corte de 0,14 y 0,17 para los dos modelos, respectivamente. Esta elección mejora la detección de las transiciones, pero implica una reducción de la especificidad y no constituye un umbral universal aplicable fuera de la muestra analizada.

En conjunto, estas limitaciones indican que los resultados deben entenderse principalmente como evidencia descriptiva y asociativa sobre los factores vinculados con la movilidad entre formalidad e informalidad, más que como evidencia causal o como un sistema de predicción definitivo. A pesar de estas restricciones, la utilización de información longitudinal de la EPH permite incorporar una dimensión dinámica que no estaría disponible mediante un análisis exclusivamente transversal y constituye una herramienta útil para caracterizar los patrones de movilidad laboral observados durante el período analizado.

7. Conclusiones

El presente trabajo tuvo como objetivo analizar la movilidad entre formalidad e informalidad en el mercado de trabajo argentino, utilizando información longitudinal de la Encuesta Permanente de Hogares (EPH) para el período comprendido entre el cuarto trimestre de 2023 y el primer trimestre de 2026. La estrategia permitió distinguir dos procesos diferentes: la transición desde un empleo formal hacia uno informal y la transición desde un empleo informal hacia uno formal.

El análisis descriptivo mostró que la movilidad entre ambas condiciones constituye un fenómeno relevante y que los dos sentidos de la transición presentan características diferentes. La construcción longitudinal de la base permitió identificar de manera específica los cambios de condición de formalidad entre períodos consecutivos, evitando confundir estas transiciones con movimientos hacia el desempleo o la inactividad.

Los modelos Logit estimados muestran que existen asociaciones diferenciadas según el sentido de la movilidad. En particular, el nivel educativo aparece como una de las características más relevantes. Los niveles educativos superiores se encuentran asociados con menores odds de transición desde la formalidad hacia la informalidad y, simultáneamente, con mayores odds de transición desde la informalidad hacia la formalidad. En el segundo modelo, esta relación presenta una magnitud particularmente marcada: respecto de la categoría educativa de referencia, el OR correspondiente a educación superior o universitaria completa alcanza aproximadamente 6.

La edad también presenta un patrón diferenciado entre ambos procesos. Una mayor edad se encuentra asociada con menores odds de transición Formal $\rightarrow$ Informal, mientras que se relaciona con mayores odds de transición Informal $\rightarrow$ Formal. La categoría ocupacional presenta igualmente asociaciones relevantes, especialmente para los trabajadores por cuenta propia, cuyo comportamiento difiere según el sentido de la transición analizada.

Las horas trabajadas y el ingreso laboral también presentan asociaciones estadísticamente significativas con la movilidad. Sin embargo, sus magnitudes deben interpretarse teniendo en cuenta las unidades de medición utilizadas. En particular, el ingreso se incorpora en miles de pesos, por lo que los odds ratios cercanos a uno corresponden al cambio asociado con un incremento relativamente pequeño del ingreso.

Desde el punto de vista predictivo, los modelos presentan una capacidad de discriminación diferente. El área bajo la curva ROC alcanza 0,7562 para Formal $\rightarrow$ Informal y 0,6736 para Informal $\rightarrow$ Formal, lo que indica que las variables incorporadas contienen información para diferenciar entre quienes realizan y quienes no realizan las transiciones analizadas, aunque existe margen para mejorar la capacidad predictiva.

El desbalance de las clases constituye un elemento central de la evaluación. El uso del umbral convencional de 0,5 produce una accuracy relativamente elevada, pero una sensibilidad muy baja para identificar las transiciones. Por este motivo, se evaluaron distintos puntos de corte mediante el indicador F1. Los valores que maximizan dicho indicador son 0,14 para Formal $\rightarrow$ Informal y 0,17 para Informal $\rightarrow$ Formal. Con estos umbrales, la sensibilidad aumenta hasta 0,461 y 0,374, respectivamente, mientras que la balanced accuracy alcanza 0,667 y 0,614. Este resultado muestra la importancia de considerar el objetivo de clasificación y el desbalance de la variable dependiente al evaluar modelos de movilidad laboral.

En términos generales, los resultados sugieren que la movilidad entre formalidad e informalidad no constituye un proceso homogéneo ni simétrico. Las características individuales y laborales asociadas con una salida de la formalidad no son necesariamente las mismas que aquellas vinculadas con una entrada a la formalidad. En particular, los resultados obtenidos para educación, edad y categoría ocupacional muestran diferencias sistemáticas entre ambos sentidos de la movilidad.

Finalmente, los resultados deben interpretarse como asociaciones condicionales y no como relaciones causales. La utilización de información longitudinal permite avanzar respecto de un análisis puramente transversal, pero las características observadas y la estrategia econométrica empleada no permiten descartar la existencia de factores no observados que influyan simultáneamente sobre las condiciones laborales y las transiciones. En este sentido, el trabajo constituye una primera caracterización econométrica de la movilidad entre formalidad e informalidad y proporciona evidencia que puede servir como punto de partida para investigaciones posteriores que incorporen especificaciones más flexibles, información adicional sobre las trayectorias laborales y estrategias orientadas específicamente a la identificación causal.